# MiniProjet1

October 1, 2023

# 1 Mini project Week 1

The mini-project for week 1 consists in coding Modified Policy Iteration and looking for the ideal number of critic updates at each iteration to converge as fast as possible on a set of 10x10 mazes. Your global report should explain or depict the set of mazes you have used, the best number of critic updates you found, and the number of iterations required on average to converge with these parameters. Think of having a key figure that makes it easy to figure out what is the best number of critic updates and how it compares to vanilla policy iteration.

### 1.1 Generalized Policy Iteration

#### 1.1.1 Generalized Policy Iteration with the Q function

```
# initial action values are set to 0
q = np.zeros((mdp.nb_states, mdp.action_space.n))
q_list = []
policy = random_policy(mdp)
stop = False
video_recorder = VideoRecorder(mdp,
                                "videos/GeneralizedPolicyIterationQ.mp4",
                               enabled=render)
mdp.init_draw("Generalized Policy iteration Q", recorder=video_recorder)
while not stop:
    qold = q.copy()
    mdp.draw_v(q, recorder=video_recorder)
    # Step 1 : Policy evaluation
    q, evaluations = evaluate_q_K_steps(mdp, policy,
                              qold, K, threshold)
    nb_evaluations += evaluations
    # Step 2 : Policy improvement
    policy = get_policy_from_q(q)
    nb_evaluations += env.action_space.n
    # Check convergence
    if (np.linalg.norm(q - qold)) <= threshold:</pre>
        stop = True
    q_list.append(np.linalg.norm(q))
mdp.draw_v_pi(q, get_policy_from_q(q), recorder=video_recorder)
video_recorder.close()
return q, q_list, nb_evaluations
```

### 1.2 Generalized Policy Iteration with the V function

```
nb_evaluations = 0
for i in range(K):
    v_old = v.copy()
    v = evaluate_one_step_v(mdp, v_old, policy)
    nb_evaluations += 1

# Test if convergence has been reached
    if (np.linalg.norm(v - v_old)) < threshold:
        break
return v, nb_evaluations</pre>
```

```
[]: def generalized_policy_iteration_v(mdp: MazeMDPEnv, K: int = 1,
                                         threshold: float = 0.01,
                                         render: bool = True) -> Tuple[np.ndarray, ___


    List[float], int]:


         """policy iteration over the V function."""
         nb_evaluations = 0
         v = np.zeros(mdp.nb_states) # initial state values are set to 0
         v_list = []
         policy = random_policy(mdp)
         stop = False
         video_recorder = VideoRecorder(mdp, "videos/GeneralizedPolicyIterationV.
      →mp4", enabled=render)
         mdp.init_draw("Policy Iteration (V)", recorder=video_recorder)
         while not stop:
             vold = v.copy()
             mdp.draw_v(v, recorder=video_recorder)
             # Step 1 : Policy Evaluation
             v, evaluations = evaluate_v_count(mdp, policy, vold, K , threshold)
             nb_evaluations += evaluations
             # Step 2 : Policy Improvement
             policy = improve_policy_from_v(mdp, v, policy)
             nb_evaluations += mdp.action_space.n
             # Check convergence
             if (np.linalg.norm(v - vold)) < threshold:</pre>
                 stop = True
             v_list.append(np.linalg.norm(v))
         mdp.draw_v_pi(v, get_policy_from_v(mdp, v), recorder=video_recorder)
```

```
video_recorder.close()
return v, v_list, nb_evaluations
```

Visualisation des résultats:

```
[]: threshold=0.00001
     K = [1, 5, 10, 15, 25, 50, 100]
     list_nb_evaluations=[]
     fig, ax = plt.subplots(figsize = (5,5))
     for k in K:
      v, norm, nb_evaluations = generalized_policy_iteration_v(env, k, threshold, __
     ⇔render=False)
      list_nb_evaluations.append(nb_evaluations)
      print(k, ":", len(norm))
      ax.plot(range(len(norm)), norm, label=k)
      ax.set(title = "convergence de v_norm en fonction du nombre de policy_
      ⇔improvement",
              xlabel = "nombre de policy improvement",
              ylabel = "v_norm")
      ax.legend(loc='best')
    plt.show()
```





Commentaire: On remarque qu'avec K=5, on obtient la même convegence qu'avec des K plus grands mais avec un nombre d'évaluation de policy optimal (12). On peut donc étudier l'impact de K sur la vitesse d'éxecution de l'algorithme generalized\_policy\_iteration\_v afin de voir s'il existe un K optimal qui permet de converger le plus rapidement possible.

#### 1.3 Etude de K sur plusieurs environnements


Etudions sur l'effet de K sur divers environnements. Cette fois, on se donne 15 labyrinthes de taille 10 par 10.

L'algorithme generalized\_policy\_iteration\_v renvoit la variable nb\_evaluations qui compte le nombre d'appel de la fonction evaluate\_one\_step\_v et qui prend également en compte la complexité de la fonction improve\_policy\_from\_v.

On considère que improve\_policy\_from\_v est mdp.action\_space.n fois plus grand en complexité que evaluate\_one\_step\_v car il réalise les mêmes calculs en utilisant une boucle for sur mdp.action\_space.n.

La variable nb\_evaluations permet donc d'avoir une idée plus précise de la complexité totale de generalized\_policy\_iteration\_v.


```
[]: envs = []
    nombre_environnements = 15
    for _ in range(nombre_environnements):
      env = gym.make("MazeMDP-v0", kwargs={"width": 10, "height": 10, "ratio": 0.
      env.metadata['render fps'] = 1
      env.reset()
       # in dynamic programming, there is no agent moving in the environment
      env.set_no_agent()
      envs.append(env)
[]: import matplotlib.pyplot as plt
    import time
    threshold=0.00001
    K = range(1, 32, 3)
    list timers = [0]*len(K)
    list_nb_evaluations = [0]*len(K)
    for j, k in enumerate(K):
      print(f"\r etape = {j+1}/{len(K)}", end="")
      start_time = time.time()
      for i, env in enumerate(envs) :
        v, norm, nb_evaluations = generalized_policy_iteration_v(env, k, threshold,__
      →render=False)
        list\_nb\_evaluations[j] \ += \ nb\_evaluations
      list_timers[j] = (time.time() - start_time)/len(envs)
      list_nb_evaluations[j] /= len(envs)
[]: fig, ax = plt.subplots(figsize = (5,5))
    ax.plot(K, list_nb_evaluations)
    ax.set(title = "nombre d'évaluations en fonction de k",
           xlabel = "k",
           ylabel = "nombre d'évaluations")
    plt.show()
```



**Commentaire :** On constate que regarder le nombre d'évaluations en fonction de k rend la conclusion difficile à cause des fortes oscillations. Il faut donc rester prudent dans nos affirmations. On remarque toutefois qu'avec k=4, on obtient le nombre minimal d'évaluations. Prendre k=4 semble donc être le choix le plus judicieux.

On peux également observer le temps de calcul necessaire à la convergence de generalized\_policy\_iteration\_v en fonction de k :

WARNING:matplotlib.legend:No artists with labels found to put in legend. Note that artists whose label start with an underscore are ignored when legend() is called with no argument.



Commentaire: On remarque d'abord que les deux courbes sont très similaires. Cela confirme qu'analyser le nombre d'épisodes comme on l'a fait est pertinent afin de trouver le K qui permet de converger le plus rapidement.

Encore une fois, k=4 minimise le temps de calcul et semble être le k à choisir dans generalized\_policy\_iteration\_v.

Ce résultat reste toutefois à relativiser compte tenu de la faible taille de notre échantillon.

# MiniProjet2

October 1, 2023

# 1 Mini project Week 2:

The mini-project for week 2 consists in coding a naive actor-critic algorithm and looking for the adequate policy and critic learning rates to converge as fast as possible on a set of 10x10 mazes. The global report should contain your actor-critic code, the values of hyper-parameters you used, and a key figure highlighting the learning behavior of your algorithm depending on the hyper-parameters, with a short discussion of your results.

## 1.1 Algorithme Actor Critic:

On commence par construire notre environnement qui est un labyrinthe de taille 10 x 10

```
import gymnasium as gym
import bbrl_gymnasium

# Environment with a little bit of negative reward (when hitting a wall)
env = gym.make("MazeMDP-v0", kwargs={"width": 10, "height": 10, "ratio": 0.2, "hit": 0.0}, render_mode="rgb_array")
env.reset()

# in dynamic programming, there is no agent moving in the environment
env.init_draw("The maze")

NB_EPISODES = 1000
```

### Output()

On réalise l'algorithme actor critic :

Ce dernier met à jour V selon l'hyperparamètre  $\alpha_{critic}$  et met la policy à jour avec un hyperparamètre  $\alpha_{actor}$ .

Ici, l'agent tire une action au hasard en suivant la policy, en utilisant la fonction np.random.choice.

L'algorithme retourne le V optimal trouvé, la policy, ainsi que les listes des V et policy mis à jour à chaque itération. Cela permettra d'étudier la vitesse de convergence de l'approche actor-critic.

```
timeout: int,
                 return_lists: bool = True
                 ) -> float:
  v = np.zeros(mdp.nb_states) # initial action values are set to 0
  policy = np.ones((mdp.nb_states, mdp.action_space.n)) / mdp.action_space.n_u
→# action probabilities are uniform
  mdp.set_timeout(timeout) # episode length
  v_list = [np.array(v)]
  policy_list = [np.argmax(policy, axis=1)]
  for i in range(nb_episodes):
      # Draw the first state of episode i using a uniform distribution over
\rightarrowall the states
      x, _ = mdp.reset(uniform=True)
      done = False
      while not done:
          u = np.random.choice(range(mdp.action_space.n), p = policy[x])
          # Perform a step of the MDP
          y, r, done, *_ = mdp.step(u)
          # critic
          delta = r + mdp.gamma * v[y] * (1 - done) - v[x]
          v[x] += alpha_critic * delta
           # actor
          policy[x, u] = max(0.02, policy[x, u] + alpha_actor * delta)
          policy[x] /= policy[x].sum()
          # Update the agent position
          x = y
      if return_lists:
          v_list.append(np.array(v))
          policy_list.append(np.argmax(policy, axis = 1))
  return v, policy.argmax(axis = 1), v_list, policy_list
```

On exécute et on visualise la policy obtenue:

Output()

On souhaite comparer nos résultats avec le  $V^*$  et la policy\* obtenus avec la fonction policy\_iteration\_v

```
[]: def improve_policy_from_v(mdp: MazeMDPEnv, v: np.ndarray,
                               policy: np.ndarray) -> np.ndarray:
         # Improves a policy given the state values
         for x in range(mdp.nb_states): # for each state x
             # Compute the value of the state x for each action u of the MDP action
      ⇔space
             if x in mdp.terminal_states:
                 policy[x] = np.argmax(mdp.r[x, :])
             else:
                 v_temp = np.zeros(mdp.action_space.n)
                 for u in range(mdp.action_space.n):
                     # Process sum of the values of the neighbouring states
                     summ = 0
                     for y in range(mdp.nb_states):
                         summ = summ + mdp.P[x, u, y] * v[y]
                     v_temp[u] = mdp.r[x, u] + mdp.gamma * summ
                 for u in range(mdp.action_space.n):
                     if v_temp[u] > v_temp[policy[x]]:
                         policy[x] = u
         return policy
     def evaluate_one_step_v(mdp: MazeMDPEnv, v: np.ndarray,
                             policy: np.ndarray) -> np.ndarray:
         # Outputs the state value function after one step of policy evaluation
         # Corresponds to one application of the Bellman Operator
         v_new = np.zeros(mdp.nb_states) # initial state values are set to 0
         for x in range(mdp.nb_states): # for each state x
             # Compute the value of the state x for each action u of the MDP action u
      ⇔space
             if x in mdp.terminal states:
                 v_new[x] = mdp.r[x, policy[x]]
             else:
                 # Process sum of the values of the neighbouring states
                 summ = 0
                 for y in range(mdp.nb_states):
                     summ = summ + mdp.P[x, policy[x], y] * v[y]
                 v_new[x] = mdp.r[x, policy[x]] + mdp.gamma * summ
         return v_new
     def evaluate_v(mdp: MazeMDPEnv, policy: np.ndarray) -> np.ndarray:
         # Outputs the state value function of a policy
         v = np.zeros(mdp.nb_states) # initial state values are set to 0
         stop = False
```

```
while not stop:
        vold = v.copy()
        v = evaluate_one_step_v(mdp, vold, policy)
        # Test if convergence has been reached
        if (np.linalg.norm(v - vold)) < 0.01:</pre>
            stop = True
    return v
def policy_iteration_v(mdp: MazeMDPEnv) -> Tuple[np.ndarray, List[float]]:
    # policy iteration over the v function
    v = np.zeros(mdp.nb_states) # initial state values are set to 0
    policy = random_policy(mdp)
    stop = False
    while not stop:
        vold = v.copy()
        # Step 1 : Policy Evaluation
        v = evaluate_v(mdp, policy)
        # Step 2 : Policy Improvement
        policy = improve_policy_from_v(mdp, v, policy)
        # Check convergence
        if (np.linalg.norm(v - vold)) < 0.01:</pre>
            stop = True
    return v, policy
```


```
[]: v_star, policy_star = policy_iteration_v(env)
env.draw_v_pi(v_star, policy_star)
```


Output()

### 1.1.1 \*\*Comparaison avec V\* et policy\*:\*\*

On va tracer les normes des différences entre V\* et V ainsi qu'entre policy\* et policy en fonction du nombre d'épisode afin d'analyser la vitesse de convergence de l'algorithme actor\_critic\_v. On essaye divers paramètres  $\alpha_{critic}$  et  $\alpha_{actor}$ 

```
v, _, v_list, policy_list = actor_critic_v(env,_
⇔nb_episodes, alpha_critic, alpha_actor, timeout)
                     axes[i, 0].plot(range(len(v_list)), [np.linalg.
→norm(v_star - v) for v in v_list],
                                    label = f"actor = {alpha_actor} ;__
⇔critic = {alpha_critic}")
                     axes[i, 0].set(xlabel = 'Number of episodes', ylabel =
axes[i, 0].legend(loc='best')
                     axes[i, 1].plot(range(len(v_list)), [np.linalg.
onorm(policy_star - policy) for policy in policy_list],
                                    label = f"actor = {alpha_actor} ;__
⇔critic = {alpha_critic}")
                     axes[i, 1].set(xlabel = 'Number of episodes', ylabel =
axes[i, 1].legend(loc='best')
      plt.subplots_adjust(hspace=0.5)
      plt.show()
```





D'une part,  $\alpha_{critic}$  règle la vitesse à laquelle l'agent ajuste ses estimations des récompenses et de la valeur des états. Ici, on voit bien qu'un  $\alpha_{critic}$  trop faible rend l'amélioration de V très lente mais plus sûre. A l'inverse, un grand  $\alpha_{critic}$  rend l'ajustement de V plus rapide mais aussi moins stable, avec beaucoup plus d'oscillations.

D'autre part,  $\alpha_{actor}$  contrôle la vitesse selon laquelle l'agent améliore sa policy. On observe donc des convergences plus fortes avec des  $\alpha_{actor}$  élevés.

Etudions plus en détail l'influence des hyperparamètres  $\alpha_{actor}$  et  $\alpha_{critic}$  afin de trouver les meilleurs. On représente la distance entre V et V\* en testant plusieurs hyperparamètres à l'aide d'une heatmap.

```
[]: list_alpha_critic = [0.01, 0.1, 0.2, 0.5, 0.6, 0.7, 0.8, 0.9, 0.99]
     list_alpha_actor = [0.01, 0.1, 0.2, 0.5, 0.6, 0.7, 0.8, 0.9, 0.99]
     liste_normes = []
     for alpha_critic in list_alpha_critic :
         normes_critic = []
         for alpha_actor in list_alpha_actor :
             v, _, _, = actor_critic_v(env, nb_episodes = 1000,_
      →alpha_critic=alpha_critic, alpha_actor=alpha_actor,
                                         timeout = 40, return lists = False)
             normes_critic.append(np.linalg.norm(v_star - v))
         liste_normes.append(normes_critic)
     # heatmap
     critic_names = [str(a) for a in list_alpha_critic]
     actor_names = [str(g) for g in list_alpha_actor]
     figure, ax = plt.subplots(figsize = (10,8))
     sns.heatmap(liste_normes, linewidth=0.5, annot = True, fmt=".4f", ax = ax)
     ax.set(title = "Heatmap de distance entre v et v_iteration en fonction de_
      →alpha_critic et alpha_actor",
            xlabel="alpha_actor", ylabel="alpha_critic")
     ax.set_xticklabels(actor_names)
     ax.set_yticklabels(critic_names)
     plt.show()
     i, j = np.argmin(liste_normes) // len(list_alpha_critic), np.
      →argmin(liste_normes) % len(list_alpha_critic)
     print(f"best_alpha_critic = {list_alpha_critic[i]}, best_alpha_actor =_u
      →{list_alpha_actor[j]}, "
           f"distance = {liste_normes[i][j]}")
```





best\_alpha\_critic = 0.6, best\_alpha\_actor = 0.99, distance = 0.24949852448929613 Ici, les hyperparamètres qui permettent d'obtenir la meilleure convergence vers V\* sont  $\alpha_{critic}=0.6$  et  $\alpha_{actor}=0.99$ 

### 1.2 Moyenne sur plusieurs environnements:

On va étudier la meilleure convergence en utilisant plusieurs environnements et en faisant une moyenne pour plus de précision:

```
[]: import gymnasium as gym
import bbrl_gymnasium


envs = []
nombre_environnements = 10

for _ in range(nombre_environnements):
```

```
env = gym.make("MazeMDP-v0", kwargs={"width": 10, "height": 10, "ratio": 0.
      env.metadata['render_fps'] = 1
       env.reset()
       # in dynamic programming, there is no agent moving in the environment
      env.set no agent()
       envs.append(env)
[]: list_alpha_critic = [0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 0.99]
    list_alpha_actor = [0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 0.99]
    moyennes_normes = np.zeros([len(list_alpha_critic), len(list_alpha_actor)])
    for e, env in enumerate(envs):
        print(f"environnement {e+1}/{len(envs)}")
        v_star, policy_star = policy_iteration_v(env)
        for i, alpha critic in enumerate(list alpha critic) :
             for j, alpha_actor in enumerate(list_alpha_actor) :
                v, _, _, = actor_critic_v(env, nb_episodes = 1000,_
      →alpha_critic=alpha_critic, alpha_actor=alpha_actor,
                                            timeout = 40, return_lists = False)
                moyennes_normes[i][j] += np.linalg.norm(v_star - v)
    moyennes_normes /= len(envs)
    environnement 1/10
    environnement 2/10
    environnement 3/10
    environnement 4/10
    environnement 5/10
    environnement 6/10
    environnement 7/10
    environnement 8/10
    environnement 9/10
    environnement 10/10
[ ]:  # heatmap
    critic_names = [str(a) for a in list_alpha_critic]
    actor_names = [str(g) for g in list_alpha_actor]
    figure, ax = plt.subplots(figsize = (10,8))
    sns.heatmap(moyennes_normes, linewidth=0.5, annot = True, fmt=".4f", ax = ax)
    ax.set(title = "Heatmap de distance entre v et v_iteration en fonction de_

¬alpha_critic et alpha_actor",
           xlabel="alpha_actor", ylabel="alpha_critic")
    ax.set_xticklabels(actor_names)
    ax.set_yticklabels(critic_names)
```





best\_alpha\_critic = 0.6, best\_alpha\_actor = 0.9, distance = 0.32164466827878774

En moyenne, sur 10 environnements, on a que les meilleurs hyperparamètres sont  $\alpha_{critic} = 0.6$  et  $\alpha_{actor} = 0.9$ . Pour un même nombre d'épisodes, ce sont ces hyperparamètres qui permettent de se rapprocher le plus de V\* en norme. On les choisit donc.